

Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Санкт-Петербургский государственный университет»

Прогнозирование болезни фитофтороза картофеля с использованием нейронных сетей

Выпускная квалификационная работа

Выполнил:

студент группы 22Б.08

Углов В. С.

Научный руководитель:

доктор ф.-м. наук, профессор

Мазалов В. В.

Санкт-Петербург, 2026

Глава 1

Введение

Эффективное управление фитосанитарными рисками в картофелеводстве требует своевременной оценки условий, при которых возрастает вероятность развития фитофтороза. Данное заболевание способно быстро распространяться в течение сезона и приводить к существенным потерям урожая, поэтому для практики важно не только фиксировать уже возникшее поражение, но и заранее получать предупреждение о повышении риска. Такая постановка задачи имеет прикладной смысл, поскольку решения о защитных мероприятиях необходимо принимать до того, как неблагоприятная ситуация станет очевидной по визуальным признакам [1, 2].

Актуальность темы определяется тем, что развитие фитофтороза тесно связано с погодными условиями. Температура воздуха, влажность, осадки и их сочетания во времени формируют среду, в которой риск развития заболевания может существенно возрастать. Традиционно подобные задачи решаются с помощью формульных и основанных на правилах схем, опирающихся на экспертно заданные пороги и индексы риска. Эти подходы сыграли важную роль в практике предупреждения заболеваний растений, однако часто ориентированы на краткосрочные предупреждения и ограничены заранее заданной структурой зависимостей между факторами. При наличии исторических сезонных данных возникает возможность использовать методы машинного и глубокого обучения, которые позволяют извлекать закономерности непосредственно из наблюдений и тем самым строить более гибкий прогноз благоприятных условий развития фитофтороза [3, 4, 5].

Цель работы заключается в разработке метода прогнозирования благоприятных условий развития фитофтороза картофеля по сезонным погодным данным на горизонте двух дней с использованием методов искусственного интеллекта.

Для достижения поставленной цели в работе решаются следующие задачи:

- проанализировать предметную область и существующие подходы к прогнозированию фитофтороза картофеля;
- исследовать структуру и состав исходных сезонных погодных данных;
- сформировать целевую переменную, соответствующую прогнозу благоприятных условий развития фитофтороза на горизонте двух дней;
- разработать схему предобработки данных и построения признаков с исключением утечки будущей информации между сезонами;
- реализовать и сравнить модели машинного и глубокого обучения в единой экспериментальной постановке;

- оценить качество полученных решений по выбранным метрикам и обосновать выбор итогового подхода.

Объектом исследования является процесс формирования благоприятных условий развития фитофтороза картофеля под воздействием погодных факторов в пределах сезонных наблюдений.

Предметом исследования являются методы и алгоритмы прогнозирования благоприятных условий развития фитофтороза картофеля по сезонным погодным данным на горизонте двух дней.

Методы исследования включают анализ научной литературы, методы преобработки табличных данных, построение производных признаков на основе временной динамики погодных наблюдений, методы машинного и глубокого обучения, а также сравнительный вычислительный эксперимент с использованием метрик оценки качества бинарной классификации.

Практическая значимость работы состоит в том, что разработанный подход может быть использован как аналитическая основа для систем поддержки принятия решений в задачах мониторинга фитосанитарного риска. Прогноз благоприятных условий развития фитофтороза на горизонте двух дней позволяет заранее оценивать вероятность неблагоприятного развития ситуации и тем самым поддерживать более обоснованное планирование защитных мероприятий.

Структура работы определяется логикой исследования. Во введении обосновывается актуальность темы, формулируются цель, задачи, объект, предмет, методы исследования и практическая значимость работы. Во второй главе рассматриваются научные публикации и существующие подходы к прогнозированию фитофтороза картофеля. В третьей главе формулируется постановка задачи и приводится описание используемых данных. Четвёртая глава посвящена преобработке данных и построению признаков. В пятой главе описываются применяемые методы и схема экспериментов. В шестой главе представлены результаты и их анализ. В заключении подводятся итоги исследования. После основной части оформляются список литературы и приложения.

Глава 2

Обзор литературы и существующих подходов

2.1 Фитофтороз картофеля как объект прогнозирования

Фитофтороз картофеля относится к числу наиболее значимых заболеваний культуры, поскольку его развитие способно быстро приводить к потерям урожая и ухудшению качества продукции. Для практики растениеводства принципиально важно не только выявлять уже возникшее поражение, но и заранее оценивать вероятность того, что в ближайшие дни сложатся условия, благоприятные для активного развития фитофтороза. Такая постановка особенно важна в ситуациях, когда решение о защитных обработках должно приниматься до появления массовых симптомов [1, 2].

Научная литература последовательно показывает, что развитие фитофтороза тесно связано с метеорологическими условиями. Наибольшее значение обычно имеют температура воздуха, относительная влажность, наличие осадков и продолжительность увлажнения поверхности растений. При этом влияние погоды не сводится к действию одного изолированного фактора: риск возрастает при определённых сочетаниях условий и их сохранении в течение некоторого времени. Иными словами, для задачи прогноза важны не только текущие погодные значения, но и их динамика на протяжении сезона [1, 3].

Именно поэтому погодные данные рассматриваются как естественная основа для построения прогностических моделей. Если удаётся заранее оценить вероятность наступления благоприятных условий развития фитофтороза, то это создаёт основу для более своевременного планирования агротехнических мероприятий. Раннее предупреждение позволяет рациональнее организовывать защиту посевов, снижать риск запаздывания обработки и одновременно избегать избыточных решений, принимаемых без учёта фактической погодной ситуации [2, 3].

2.2 Традиционные подходы к прогнозированию фитофтороза

Исторически задача прогнозирования фитофтороза решалась прежде всего с помощью формульных, экспертных и основанных на правилах подходов. Их общая

идея состоит в том, что специалист заранее задаёт правила, связывающие погодные условия с уровнем риска. В литературе и прикладных системах поддержки принятия решений широко обсуждаются схемы, основанные на погодных порогах, индексах риска и накоплении баллов опасности. К числу наиболее известных примеров относятся подходы семейства *BLITECAST*, *SIMCAST*, а также схемы, опирающиеся на показатели типа *DSV* [3, 6].

Подобные системы, как правило, ориентированы на практическое предупреждение в коротком временном горизонте. Их задача состоит не в построении общего описания эпидемического процесса, а в том, чтобы по наблюдаемым погодным условиям определить, возникло ли окно повышенного риска и требуется ли вмешательство. Поэтому в основе таких моделей лежат сравнительно простые правила: при достижении заданных сочетаний температуры, влажности и длительности увлажнения риск считается повышенным; затем эти состояния могут суммироваться или накапливаться до момента, когда формируется предупреждение [3, 6].

Сильная сторона традиционных подходов заключается в их прозрачности. Они опираются на предметные представления о развитии болезни, сравнительно легко интерпретируются и хорошо встраиваются в агрономическую практику. Для пользователя важно, что результат таких систем можно непосредственно связать с набором наблюдаемых условий и с конкретным управленческим решением. Кроме того, схемы, основанные на правилах, не требуют больших исторических выборок для обучения, поскольку их логика задаётся заранее, а не извлекается автоматически из данных [3, 2].

2.3 Ограничения существующих подходов

Несмотря на практическую ценность традиционных схем, их возможности ограничены самой природой фиксированных правил. Во-первых, заранее заданные погодные пороги не всегда одинаково хорошо работают в разных условиях наблюдения. Реальная динамика заболевания зависит от конкретного сезона, локальных особенностей климата, структуры наблюдений и качества исходных данных. Поэтому правила, показавшие приемлемый результат в одной среде, могут переноситься в другую среду лишь частично [3].

Во-вторых, формульные системы обычно опираются на сравнительно жёсткую структуру признаков. Даже если они используют накопительные индексы, сами зависимости между погодными переменными задаются разработчиком заранее. Это затрудняет учёт более сложных взаимодействий факторов, когда риск определяется не отдельным порогом, а комбинацией нескольких признаков и их изменением во времени. В результате такие подходы хорошо подходят для оперативного краткосрочного предупреждения, но хуже отражают сезонный контекст и неоднородность исторических наблюдений [3].

В-третьих, для систем, основанных на правилах, характерна ориентация именно на короткие окна риска. Такой подход оправдан с практической точки зрения, однако он не всегда позволяет использовать более длинную историю погодных наблюдений как источник дополнительной информации. Между тем для прогностической задачи может быть важен не только текущий день, но и то, в каких условиях развивался сезон ранее, насколько устойчивыми были влажные периоды и как менялись погодные характеристики в предшествующие дни [3, 6].

Таким образом, основное ограничение традиционных систем состоит не в том,

что они непригодны, а в том, что их выразительность заранее ограничена набором экспертно заданных правил. Это делает их полезной отправной точкой, но оставляет пространство для подходов, которые способны извлекать зависимости из накопленных наблюдений и адаптироваться к структуре конкретных данных [3, 4].

2.4 Машинное обучение как развитие погодного прогноза риска

На этом фоне использование методов машинного и глубокого обучения представляется естественным развитием задачи. В отличие от схем, основанных на правилах, такие методы не требуют заранее фиксировать все зависимости между признаками и целевой переменной. Они позволяют обучать модель на исторических данных и тем самым выявлять связи между погодными характеристиками и риском развития фитофтороза непосредственно из наблюдений. Это особенно важно в задачах, где существенную роль играют совместное влияние нескольких факторов, нелинейные эффекты и история изменения признаков [4, 7, 8].

Для задач прогноза заболеваний растений принципиально важно различать диагностику по изображениям и прогнозирование по погодным данным. В настоящей работе рассматривается именно второй тип задачи: модель получает на вход сезонные метеорологические признаки и должна оценить, насколько вероятны благоприятные условия развития фитофтороза в ближайшем будущем. Такой подход ближе не к распознаванию уже имеющихся симптомов, а к поддержке превентивного принятия решений [5, 4].

Преимущество методов машинного обучения в данной постановке состоит в том, что они могут использовать как исходные погодные признаки, так и производные характеристики, отражающие краткосрочную и сезонную динамику. Это создаёт возможность работать не только с отдельными значениями температуры или влажности, но и с их сочетаниями, лагами, сглаженными показателями и другими признаками, формируемыми на основе исторических наблюдений. В результате модель получает более гибкое описание среды, чем при использовании только фиксированных порогов [4, 7, 9, 10].

Вместе с тем литература и практика показывают, что выбор конкретного класса моделей должен определяться не модностью метода, а свойствами данных и постановкой задачи. Для структурированных сезонных выборок оправдано сравнение нескольких семейств подходов, включая табличные модели и последовательные нейросетевые архитектуры. Более сложная модель сама по себе не гарантирует лучшего результата, если объём данных ограничен, а сигнал определяется в первую очередь качеством признакового описания и корректностью экспериментальной схемы [5, 9, 10].

Именно эта логика и мотивирует постановку настоящей работы. Имеются исторические сезонные погодные данные, разделённые по годам, и требуется построить бинарный прогноз благоприятных условий развития фитофтороза на горизонте двух дней. В такой задаче уместно использовать подход на основе методов машинного и глубокого обучения, однако применять его необходимо с учётом предметной специфики, сезонной структуры наблюдений и обязательного исключения утечки будущей информации между сезонами.

Выводы по главе

Обзор литературы показывает, что задача прогнозирования фитофтороза картофеля имеет ясное практическое и научное основание: развитие болезни тесно связано с погодными условиями, а раннее предупреждение необходимо для своевременной организации защитных мероприятий. Традиционные системы прогнозирования сформировали важную основу для решения этой задачи, однако их преимущественно формульный и основанный на правилах характер ограничивает гибкость описания сезонной динамики и сложных сочетаний факторов. Это делает обоснованным обращение к методам машинного и глубокого обучения, которые позволяют извлекать зависимости из исторических данных и строить прогноз в постановке, соответствующей целям настоящей работы [3, 4, 9].

Глава 3

Постановка задачи и описание данных

3.1 Формальная постановка задачи

На основании рассмотренного научного контекста в настоящей работе решается задача прогнозирования благоприятных условий развития фитофтороза картофеля по погодным данным. В терминах машинного обучения она формулируется как задача бинарной классификации. Для каждого объекта наблюдения по набору ежедневных погодных и производных признаков требуется определить, сложатся ли через два дня условия, благоприятные для развития фитофтороза.

Пусть каждому дню внутри отдельного сезона соответствует вектор признаков $x \in X$, включающий ежедневные погодные показатели и построенные на их основе производные характеристики. Тогда требуется построить отображение

$$f : X \rightarrow \{0, 1\},$$

где значение 0 соответствует отсутствию благоприятных условий развития фитофтороза на целевом горизонте, а значение 1 — их наличию. Таким образом, входом модели выступает признаковое описание текущего состояния погодной среды, а выходом — бинарный прогноз благоприятных условий развития фитофтороза на горизонте двух дней.

Содержательно данная постановка ориентирована не на диагностику уже наблюдаемого поражения растений, а на раннее предупреждение. Это означает, что модель должна использовать только ту информацию, которая доступна к моменту формирования прогноза, и не должна опираться на сведения из будущих дней. Вследствие этого ключевым методологическим требованием становится исключение утечки будущей информации как при формировании признаков, так и при разбиении данных на обучающие и контрольные части.

3.2 Описание исходных данных

В работе используются исторические метеорологические наблюдения за летние периоды (май–сентябрь) с 1972 по 2011 годы для района г. Гатчина. Наблюдения организованы в виде отдельных сезонных фрагментов по годам. Временной ряд является неполным: суммарно отсутствуют данные примерно за 12 лет, что обусловлено особенностями архивирования и источников измерений.

Исходный массив был неоднородным: часть наблюдений содержала календарные даты, часть — только номер дня года; названия признаков различались между источниками; присутствовали пропуски и различия в форматах представления. Поэтому на этапе предварительной обработки все данные были приведены к единому формату, после чего стало возможным сформировать согласованное признаковое описание для обучения моделей.

Под объектом в данной задаче понимается отдельное ежедневное наблюдение, для которого формируется бинарная целевая переменная. В качестве базового набора используются ежедневные погодные и производные признаки, объединённые в 14 столбцов:

- `day` — номер дня года;
- `T_min`, `T_max`, `T_avg` — минимальная, максимальная и средняя температура воздуха;
- `Is_rain` — бинарный индикатор наличия осадков;
- `Precipitation` — количество осадков;
- `Cloudiness` — степень облачности;
- `T > 10`, `Precipitation_T_gt_10` — индикаторы условий при температуре выше 10°C;
- `Y1`, `Y2`, `Y3`, `Y4` — производные признаки, вычисляемые по аналитическим формулам на основе исходных метеопараметров;
- `Target_Favorable` — бинарная целевая переменная, отражающая наличие благоприятных условий для развития фитофтороза в последующие дни.

3.3 Сезонная структура данных

Сезонная организация данных, описанная выше, является принципиальной особенностью данной задачи. Наблюдения не образуют единую однородную временную последовательность, а представлены отдельными фрагментами по годам. Каждый такой фрагмент отражает самостоятельный сезон, внутри которого погодные характеристики связаны общей динамикой, тогда как объединение наблюдений из разных лет в один непрерывный ряд было бы методологически некорректным.

Именно поэтому при построении модели необходимо сохранять границы сезонов на всех этапах обработки. Разбиение данных на обучающую, валидационную и тестовую части должно выполняться по годам, а не по отдельным дням, чтобы признаки, целевые значения и статистики, сформированные внутри одного сезона, не использовали информацию из другого. Такой подход позволяет избежать утечки будущих данных между сезонами и делает оценку качества модели более корректной с точки зрения реального сценария применения.

Подчёркивание сезонной структуры важно и с содержательной точки зрения. Риск развития фитофтороза определяется не только погодой конкретного дня, но и предшествующим ходом сезона. Поэтому модель должна учитывать внутрисезонную динамику, не нарушая при этом естественную изоляцию годовых фрагментов.

Данное требование напрямую влияет как на процедуру подготовки данных, так и на интерпретацию получаемых результатов.

3.4 Распределение классов и характеристика целевой переменной

После формирования целевой переменной `Target_Favorable` по её распределению видно, что отрицательный класс заметно преобладает: к классу 0 отнесены 1592 наблюдения (74.88%), а к классу 1 — 533 наблюдения (25.07%). Такое соотношение указывает на выраженный дисбаланс в пользу отрицательного класса, то есть ситуаций, в которых благоприятные условия развития фитофтороза не фиксируются.

Наличие дисбаланса классов важно для последующей постановки вычислительного эксперимента. В подобных условиях качество модели нецелесообразно оценивать только по доле правильных ответов, поскольку такая метрика может скрывать слабую способность выявлять именно положительный класс. Поэтому уже на этапе описания данных необходимо учитывать, что задача связана не только с построением бинарного прогноза, но и с корректной оценкой модели в условиях неравномерного распределения целевой переменной [11, 12, 13, 14].

Выводы по главе

Таким образом, задача исследования была формализована как задача бинарной классификации, в которой по ежедневным погодным и производным признакам требуется спрогнозировать благоприятные условия развития фитофтороза картофеля на горизонте двух дней. Показано, что исходные данные имеют сезонную структуру и представлены отдельными годовыми фрагментами, поэтому при подготовке выборки необходимо сохранять границы сезонов и исключать утечку будущей информации между ними. Кроме того, распределение целевой переменной указывает на дисбаланс классов, что следует учитывать при дальнейшей организации экспериментов и выборе метрик качества. Это позволяет перейти к описанию схемы предобработки и построения признаков.

Глава 4

Предобработка данных и построение признаков

4.1 Логика подготовки данных

После формальной постановки задачи ключевым этапом исследования становится построение согласованного конвейера подготовки данных. В данной работе предобработка рассматривается не как набор разрозненных технических операций, а как последовательность шагов, которые обеспечивают корректность будущего прогноза. Поскольку модель должна использовать ежедневные погодные и производные признаки для предсказания благоприятных условий развития фитофтороза на горизонте двух дней, любая ошибка в структуре временных рядов, обработке пропусков или формировании признаков непосредственно влияет на качество и интерпретируемость результата.

Основой этого конвейера является базовое признаковое представление, включающее 14 столбцов, используемых для обучения. Именно это представление служит отправной точкой для дальнейших преобразований. Все последующие шаги — приведение признаков к единому формату, восстановление корректной сезонной последовательности дней, обработка пропусков, построение временных и комбинированных признаков, а также разбиение данных по годам — подчинены одной задаче: получить обучающую выборку, которая отражает реальную структуру наблюдений и не содержит утечки будущей информации.

4.2 Приведение признаков к единому формату

Первым шагом подготовки данных стало приведение исходных признаков к единому формату. Для задач, основанных на сезонных погодных наблюдениях, это необходимо не только для удобства дальнейшей обработки, но и для обеспечения согласованности всех этапов конвейера подготовки данных. Нормализация наименований признаков, проверка типов данных и устранение неоднозначностей в представлении переменных позволяют рассматривать набор данных как единую структурированную таблицу, пригодную для воспроизводимого построения моделей.

Содержательный смысл этого этапа состоит в том, что дальнейшее формирование признаков должно опираться на устойчивую и однозначную схему данных. Если один и тот же погодный показатель представлен в разных форматах или интерпретируется

неодинаково в разных сезонных фрагментах, то сравнение наблюдений и вычисление производных характеристик становится некорректным. Поэтому унификация признакового пространства является необходимым условием для последующего построения как базовых, так и расширенных вариантов признаков.

4.3 Корректировка сезонных последовательностей и обработка пропусков

Следующим этапом стало исправление повреждённых последовательностей дней внутри сезонных фрагментов. Для данной задачи порядок наблюдений принципиален, поскольку прогноз строится на временном горизонте, а часть признаков формируется на основе предшествующих значений. Нарушения в сезонной последовательности дней приводят к тому, что лаговые и скользящие характеристики начинают отражать не реальную динамику сезона, а артефакты структуры данных. Поэтому до построения производных признаков было необходимо восстановить корректную упорядоченность наблюдений внутри каждого года.

После этого выполнялась обработка пропусков. В условиях погодных рядов отсутствие отдельных значений является практически неизбежным, однако прямое удаление всех таких наблюдений привело бы к дополнительной потере и без того ограниченного объёма выборки. Вместо этого пропуски обрабатывались внутри общей схемы подготовки данных, что обеспечивало воспроизводимость процедуры и исключало некорректное использование информации из контрольных частей выборки. Принципиально важно, что операции, зависящие от распределения данных, выполнялись в рамках обучения и оценивания, а не заранее на всей выборке.

Таким образом, корректировка сезонных последовательностей и обработка пропусков решают две разные, но взаимосвязанные задачи. Первая обеспечивает временную корректность данных, вторая — их полноту и пригодность для обучения моделей. Только после этого становится возможным осмысленное построение производных признаков.

4.4 Построение признаков

После приведения данных к единой структуре и устранения нарушений во временной организации формировались различные варианты признакового описания. Базовым вариантом являлось представление *baseline*, опирающееся на исходные 14 столбцов после их очистки и унификации. Этот вариант задаёт минимально необходимое описание погодной ситуации и служит отправной точкой для сравнения с более сложными схемами инженерии признаков.

Следующий вариант связан с построением *interaction*-признаков. Его идея состоит в том, что влияние погодных факторов на риск развития фитофтороза определяется не только их отдельными значениями, но и их сочетаниями. Поэтому в расширенном признаковом пространстве учитывались взаимодействия между исходными переменными, позволяющие модели использовать совместный эффект нескольких факторов без необходимости задавать такие зависимости вручную в форме фиксированных правил [4, 7].

Отдельную роль играют *temporal*-признаки, отражающие краткосрочную динамику погодных условий. В эту группу входят лаговые и скользящие характеристики,

вычисляемые на основе предшествующих наблюдений. Лаговые признаки позволяют включить в описание объекта информацию о значениях переменных в предыдущие дни, а скользящие характеристики — зафиксировать локальные усреднённые или сглаженные свойства временного ряда. Для данной задачи это особенно важно, поскольку благоприятные условия развития фитофтороза зависят не только от погодной ситуации в отдельный день, но и от её предшествующей динамики [9, 10].

Принципиально важно, что лаговые и rolling-признаки строились строго внутри каждого года. Это означает, что при вычислении временных характеристик для очередного объекта использовались только предшествующие наблюдения текущего сезонного фрагмента. Такой подход исключает искусственное «протекание» информации через границы лет и сохраняет реальный смысл сезонной динамики.

Помимо отдельных схем использовались и комбинированные варианты признаков, объединяющие несколько подходов. В частности, рассматривались комбинации *baseline*, *interaction* и *temporal*, а также варианты, связанные с применением процедуры *Tomek*. В данной логике *Tomek*-комбинации рассматривались не как самостоятельный тип исходных погодных признаков, а как часть расширенной схемы подготовки обучающей выборки, в которой признаковое представление сочеталось с дополнительной обработкой граничных наблюдений между классами. Это позволяло сравнивать не только влияние самих признаков, но и эффект их использования в сочетании с более аккуратной организацией обучающего набора [11].

4.5 Разбиение данных по годам и предотвращение утечки будущей информации

Разбиение данных на обучающую, валидационную и тестовую выборки по годам является в данной работе принципиальным требованием, а не просто удобным техническим решением. Если бы выборка делилась случайным образом по отдельным дням, то наблюдения из одного и того же сезона могли бы одновременно оказаться в обучающей и контрольной частях. В этом случае модель фактически получала бы доступ к близким по структуре участкам одного и того же сезонного ряда, а оценка качества становилась бы излишне оптимистичной.

Разделение по годам устраняет эту проблему и лучше соответствует реальному сценарию применения модели. На практике прогноз должен строиться для нового сезонного фрагмента, который не использовался при обучении. Следовательно, корректная экспериментальная схема должна воспроизводить именно такую ситуацию: модель обучается на одних сезонах, настраивается на других и проверяется на годах, полностью исключённых из этапа обучения.

Принцип предотвращения утечки будущих данных распространяется не только на само разбиение, но и на весь конвейер подготовки данных. Обработка пропусков, построение производных признаков и любые преобразования, зависящие от статистик обучающей выборки, должны быть организованы так, чтобы сведения из валидационной и тестовой частей не влияли на обучение модели. Временные признаки при этом формируются только по прошлым наблюдениям внутри соответствующего года, а межсезонные переходы не используются как источник информации. Именно такая организация эксперимента позволяет считать итоговые результаты содержательно корректными.

Выводы по главе

Итак, предобработка данных была организована как единый конвейер, обеспечивающий корректность признакового описания и воспроизводимость вычислительного эксперимента. На базовом уровне использовались 14 столбцов, приведённых к единому формату и очищенных от структурных несогласованностей. Внутри каждого сезонного фрагмента были исправлены повреждённые последовательности дней, обработаны пропуски и сформированы различные варианты признаков: *baseline*, *interaction*, *temporal* и их комбинации с процедурой *Totek*. Принципиально важным условием всей схемы стало разбиение данных по годам и исключение утечки будущей информации, поскольку только такая организация позволяет корректно оценивать модель в задаче сезонного прогноза. На этой основе далее проводится сравнение моделей.

Глава 5

Методы и схема экспериментов

5.1 Общая логика сравнения моделей

После формирования корректного признакового пространства задача исследования переходит в этап сравнительного анализа моделей. В настоящей работе эксперименты строятся вокруг одного рабочего сценария: по ежедневным погодным и производным признакам требуется спрогнозировать благоприятные условия развития фитофтороза картофеля на горизонте двух дней. При этом для табличного представления использовалось окно длиной 7 дней, позволяющее включить в описание объекта не только текущую погодную ситуацию, но и краткосрочный предшествующий контекст.

Сравнение проводилось в единой экспериментальной схеме. Это означает, что разные модели обучались и оценивались при согласованной постановке задачи, на сопоставимых вариантах признаков и при одинаковой логике разделения данных по годам. Такой подход необходим для того, чтобы различия в итоговом качестве можно было связывать именно со свойствами моделей и признакового описания, а не с изменением условий эксперимента.

В исследование были включены три группы подходов: табличные модели машинного обучения, последовательные модели глубокого обучения и ансамблевые решения. Такое распределение соответствует структуре самой задачи. С одной стороны, погодные и производные признаки образуют табличное пространство, в котором естественно проверять классические и нелинейные ML-модели. С другой стороны, сезонный характер данных делает содержательно оправданным использование последовательных архитектур, способных учитывать временную динамику. Ансамблевые методы, в свою очередь, позволяют проверить, даёт ли объединение сильных индивидуальных решений дополнительный выигрыш в качестве прогноза.

5.2 Используемые модели

В качестве базовых табличных моделей рассматривались *Logistic Regression* и *SVM*. Их выбор обусловлен тем, что обе модели являются стандартной точкой отсчёта в задачах бинарной классификации на структурированных данных. *Logistic Regression* задаёт простой и интерпретируемый линейный ориентир, а *SVM* позволяет проверить, насколько разделение классов может быть улучшено за счёт более гибкой границы решений. В данной работе эти модели выполняют роль не только самостоятельных кандидатов, но и базового уровня, с которым сопоставляются более сложные методы.

Для оценки преимуществ нелинейного табличного моделирования использовались *RandomForest* и *XGBoost*. Их включение в экспериментальную схему связано с тем, что погодные факторы и производные признаки могут взаимодействовать нелинейно, а качество прогноза часто определяется сочетанием нескольких переменных. Поэтому деревья решений и бустинг рассматриваются как естественное расширение линейных базовых подходов.

Последовательные модели глубокого обучения были представлены архитектурами *GRU* и *TFT*. Их выбор обусловлен тем, что задача имеет выраженную временную природу: риск развития фитофтороза зависит не только от текущего дня, но и от предшествующей динамики погодных условий. *GRU* включалась как компактная рекуррентная модель для работы с последовательностями, тогда как *TFT* рассматривалась как более сложный подход, ориентированный на обработку временных зависимостей и разнородных признаков. При этом в работе данные модели анализировались не как самоцель, а как содержательно мотивированная проверка гипотезы о пользе последовательного представления данных.

Ансамблевый подход был представлен моделью *Voting ensemble*. Его использование позволяло оценить, способен ли агрегированный прогноз объединить сильные стороны нескольких индивидуальных моделей и тем самым дать более устойчивый результат. Включение ансамбля в эксперимент особенно важно в условиях, когда разные семейства методов по-разному реагируют на структуру признаков и дисбаланс классов.

5.3 Варианты признаков и подбор гиперпараметров

Сравнение моделей выполнялось не на одном фиксированном наборе признаков, а на нескольких вариантах признакового описания. В экспериментальную схему были включены представления *baseline*, *interaction*, *temporal*, а также их комбинированные варианты с использованием процедуры *Tomek*. Такая организация эксперимента позволяла оценить не только различия между моделями, но и вклад инженерии признаков в итоговое качество прогноза.

Логика сравнения состояла в следующем. Сначала модели проверялись на более простом признаковом описании, после чего сопоставлялись с вариантами, в которых учитывались взаимодействия между признаками, краткосрочная временная динамика и более аккуратная организация обучающей выборки. Благодаря этому итоговый вывод строился не на абстрактном сравнении алгоритмов, а на сопоставлении целостных решений, включающих и тип модели, и способ представления данных.

Для наилучшей настройки моделей использовался подбор гиперпараметров. Его применение было необходимо, поскольку прямое сравнение методов при произвольных настройках дало бы методологически слабый результат. Подбор гиперпараметров позволял адаптировать модели к рассматриваемой задаче и снижал риск того, что качество отдельного подхода будет недооценено из-за неудачного выбора параметров.

5.4 Единая экспериментальная схема

Корректность сравнения в данной работе обеспечивалась единой экспериментальной схемой. Во всех случаях сохранялись одинаковые ключевые условия: рабочий горизонт прогноза составлял 2 дня, табличное окно — 7 дней, а разделение данных выполнялось

по годам с исключением утечки будущей информации. Это означает, что различия между результатами интерпретируются как следствие различий между методами и вариантами признаков, а не как эффект изменения экспериментальной постановки.

Особое значение имеет то, что последовательные модели, табличные методы и ансамбли сравнивались в рамках одной и той же исследовательской задачи. Такой подход позволяет избежать искусственного противопоставления разных семейств моделей и вместо этого сосредоточиться на их практической пригодности для сезонного прогноза. Именно в такой схеме можно содержательно ответить на вопрос, какие методы лучше работают на доступном объёме погодных данных и при выбранном способе представления признаков.

5.5 Метрики оценки качества

Для оценки результатов использовались метрики *Precision*, *Recall*, *F1-score*, *ROC-AUC*, *PR-AUC*, а также матрица ошибок. Такой набор метрик позволяет рассматривать качество бинарной модели с нескольких точек зрения и не ограничиваться одной агрегированной характеристикой.

Метрика *Precision* показывает, какая доля объектов, отнесённых моделью к положительному классу, действительно соответствует благоприятным условиям развития фитофтороза. Для прикладной задачи это важно потому, что низкое значение *Precision* означает большое число ложных предупреждений. Метрика *Recall*, напротив, отражает способность модели обнаруживать действительно опасные ситуации. В контексте фитосанитарного прогноза снижение *Recall* означает рост числа пропущенных случаев, когда риск развития фитофтороза был недооценён.

F1-score использовался как согласованная характеристика баланса между *Precision* и *Recall*. Эта метрика полезна тогда, когда требуется учитывать одновременно и точность положительных срабатываний, и полноту выявления рискованных ситуаций. Вместе с тем для более полного анализа использовались и порогонезависимые метрики.

ROC-AUC позволяет оценить способность модели разделять классы в широком диапазоне порогов. Однако в условиях дисбаланса классов этой характеристики недостаточно для содержательной интерпретации результата. По этой причине особое значение в работе имеют *Precision*, *Recall* и *PR-AUC*. Последняя метрика непосредственно отражает качество модели по кривой precision–recall и потому лучше согласуется с задачами, где положительный класс встречается реже и представляет наибольший практический интерес.

Дополнительную интерпретацию результатов обеспечивает матрица ошибок, позволяющая напрямую увидеть соотношение истинно положительных, ложноположительных, истинно отрицательных и ложноотрицательных решений. Для прикладной задачи прогноза фитофтороза это важно, поскольку итоговое качество должно оцениваться не только формально, но и через характер совершаемых ошибок. Именно поэтому в дальнейшем основной акцент при анализе результатов делается на *Precision*, *Recall* и *PR-AUC*, а остальные метрики используются как дополняющие характеристики модели.

Выводы по главе

Итак, в работе была задана единая схема сравнения методов. В одной постановке сопоставлялись табличные модели *Logistic Regression*, *SVM*, *RandomForest*, *XGBoost*, последовательные модели *GRU* и *TFT*, а также ансамблевый подход *Voting ensemble*. Сравнение выполнялось на разных вариантах признаков при горизонте прогноза 2 дня и табличном окне 7 дней с использованием подбора гиперпараметров и разбиения данных по годам. Для оценки качества применялись метрики *Precision*, *Recall*, *F1-score*, *ROC-AUC*, *PR-AUC* и матрица ошибок; при этом из-за дисбаланса классов особое внимание уделялось *Precision*, *Recall* и *PR-AUC*. Это задаёт основу для анализа полученных результатов.

Глава 6

Результаты и их анализ

6.1 Основные результаты экспериментов

Проведённое сравнение моделей показало, что наилучший итоговый результат в рассматриваемой постановке был получен моделью *Logistic Regression*. Лучшее решение достигалось при использовании варианта признаков `tomek_interaction_temporal_fe`, то есть при сочетании расширенного признакового описания с дополнительной обработкой обучающей выборки. Этот результат важен сам по себе, поскольку показывает, что в данной задаче ключевую роль играет не только выбор класса модели, но и качество представления данных.

Для лучшего итогового варианта были получены следующие значения метрик: *Precision* — 0.662, *Recall* — 0.764, *F1-score* — 0.709, *ROC-AUC* — 0.913 и *PR-AUC* — 0.729. Таким образом, модель показала высокий уровень разделения классов и одновременно сохранила содержательно важный баланс между точностью положительных срабатываний и полнотой выявления рискованных ситуаций. С учётом дисбаланса классов именно сочетание *Precision*, *Recall* и *PR-AUC* даёт наиболее информативную картину качества, поэтому данный результат можно рассматривать как устойчивый не только в формальном, но и в прикладном смысле.

Анализ матрицы ошибок также подтверждает практическую состоятельность итогового решения. Для лучшей модели получены значения $TN = 291$, $FP = 48$, $FN = 29$ и $TP = 94$. Это означает, что модель обнаруживает значительную часть действительно благоприятных для развития фитофтороза ситуаций, сохраняя при этом контролируемый уровень ложных предупреждений. С исследовательской точки зрения здесь особенно важно то, что итоговый результат не сводится к механическому росту одной метрики: он отражает именно рабочий компромисс между пропуском опасных случаев и избыточными сигналами тревоги.

6.2 Сравнительный анализ моделей

Общая картина экспериментов показывает, что на доступном объёме сезонных данных табличные модели оказались сильнее последовательных нейросетевых подходов. Этот вывод важен, поскольку он противостоит распространённому предположению о том, что усложнение архитектуры автоматически должно приводить к улучшению качества прогноза. В рассматриваемой задаче такого эффекта не наблюдалось: более сложные последовательные модели не дали преимущества, которое позволило бы превзойти лучшие табличные решения.

Полученный результат согласуется со структурой исходной задачи. Данные имеют сравнительно ограниченный объём, выраженную сезонную сегментацию по годам и табличное представление признаков, дополненное инженерией признаков. В таких условиях табличные модели способны эффективно использовать информацию о взаимодействиях факторов и краткосрочной динамике без необходимости в чрезмерно сложной архитектуре. Поэтому итоговое лидерство *Logistic Regression* следует интерпретировать не как случайный результат, а как показатель того, что для данной постановки адекватное признаковое описание оказалось важнее архитектурной сложности.

Отдельного упоминания заслуживает ансамблевый подход *Voting ensemble*. В проведённых экспериментах он показал конкурентоспособный результат и подтвердил, что агрегирование прогнозов может быть полезным направлением сравнения. Однако даже на этом фоне наилучший результат остался за *Logistic Regression*, что дополнительно подчёркивает силу корректно настроенной базовой табличной модели в задаче сезонного прогноза.

6.3 Роль признакового описания и экспериментальной схемы

Результаты экспериментов показывают, что качество прогноза в значительной степени определялось не только выбором модели, но и организацией всей исследовательской схемы. Существенное влияние на итоговые показатели оказали инженерия признаков и корректное разбиение данных по годам. Иными словами, улучшение качества достигалось не за счёт формального усложнения алгоритма, а за счёт более содержательного описания погодной ситуации и более строгой постановки вычислительного эксперимента.

Лучший результат был получен именно на признаковом варианте `tomek_interaction_temporal_fe`, что подтверждает значимость объединения нескольких источников информативности. Взаимодействия между признаками позволяют лучше учитывать совместное влияние погодных факторов, временные характеристики отражают предшествующую динамику сезона, а аккуратная работа с граничными наблюдениями усиливает обучающую постановку. В совокупности это даёт более полное описание среды, чем исходное базовое представление.

Не менее важным фактором оказалось разбиение данных по годам. Если бы сравнение выполнялось без строгого учёта сезонных границ, то часть качества могла бы объясняться утечкой информации между близкими по структуре участками временных рядов. В проведённой работе такой риск был исключён, поэтому полученные результаты можно интерпретировать как более надёжную оценку реальной прогностической способности моделей. Именно по этой причине итоговый вывод о преимуществе табличных моделей и лидерстве *Logistic Regression* имеет не только эмпирическую, но и методологическую ценность.

Краткие выводы по результатам

- Лучший итоговый результат получен моделью *Logistic Regression* на варианте признаков `tomek_interaction_temporal_fe`.

- Достигнутые значения *Precision* 0.662, *Recall* 0.764, *F1-score* 0.709, *ROC-AUC* 0.913 и *PR-AUC* 0.729 указывают на качественный и практически значимый прогноз.
- На доступном объёме сезонных данных табличные модели оказались сильнее последовательных нейросетевых подходов.
- *Logistic Regression* показала лучший баланс между *Precision* и *Recall*, а *Voting ensemble* подтвердил ценность ансамблевого сравнения как сильный сравнительный ориентир.
- Инженерия признаков и корректное годовое разбиение существенно повлияли на качество, тогда как усложнение архитектуры само по себе не гарантировало улучшения результата.

Ограничения исследования

- Исследование выполнено на доступном объёме сезонных данных, что естественным образом ограничивает устойчивость выводов для более сложных моделей.
- Целевая переменная характеризуется дисбалансом классов, поэтому даже при хорошем качестве модели задача остаётся чувствительной к компромиссу между ложными предупреждениями и пропусками рискованных случаев.
- Результаты относятся к постановке прогноза по погодным и производным признакам на горизонте 2 дня; переносимость выводов на иные условия применения требует отдельной проверки.
- Значительная часть качества зависит от выбранной схемы построения признаков, поэтому итоговые выводы следует интерпретировать в контексте использованной схемы подготовки данных.

Направления дальнейшего развития

- Расширить набор сезонных данных и проверить устойчивость результатов на более широком временном материале.
- Исследовать дополнительные варианты инженерии признаков, сохраняющие интерпретируемость и сезонную корректность признаков.
- Продолжить анализ ансамблевых решений, включая более гибкие способы объединения сильных табличных моделей.
- Проверить, как изменяется качество прогноза при переносе подхода на другие условия наблюдения и при расширении набора входных факторов.

Глава 7

Заключение

Выполненная работа была посвящена разработке метода прогнозирования благоприятных условий развития фитофтороза картофеля по сезонным погодным данным на горизонте двух дней с использованием методов искусственного интеллекта. В ходе исследования была последовательно решена вся цепочка задач, необходимая для получения итогового результата: был проведён анализ предметной области и существующих подходов, была сформулирована постановка задачи бинарной классификации, были описаны и проанализированы исходные данные, а также была обоснована необходимость раздельного рассмотрения сезонных фрагментов по годам.

На следующем этапе был реализован целостный конвейер подготовки данных. Были приведены к единому формату исходные признаки, были исправлены повреждённые последовательности дней, была выполнена обработка пропусков и были построены различные варианты признакового описания, включая *baseline*, *interaction*, *temporal* и их комбинации с процедурой *Tomek*. Принципиально важным условием всей работы стало исключение утечки будущей информации, что было обеспечено как при построении временных признаков, так и при разбиении данных на обучающую, валидационную и тестовую части по годам.

Далее были реализованы и сопоставлены модели *Logistic Regression*, *SVM*, *RandomForest*, *XGBoost*, *GRU*, *TFT* и *Voting ensemble* в единой экспериментальной схеме. Проведённые эксперименты показали, что на доступном объёме сезонных данных табличные модели оказались сильнее последовательных нейросетевых подходов. Лучший итоговый результат был получен моделью *Logistic Regression* на варианте признаков *tomek_interaction_temporal_fe*. Для этого решения были достигнуты значения *Precision* 0.662, *Recall* 0.764, *F1-score* 0.709, *ROC-AUC* 0.913 и *PR-AUC* 0.729 при матрице ошибок $TN = 291$, $FP = 48$, $FN = 29$, $TP = 94$. Тем самым был получен практически значимый результат, показывающий, что корректно организованный подход на основе методов машинного обучения способен обеспечивать качественный прогноз риска в задаче сезонного фитосанитарного мониторинга.

Значимость полученного результата заключается в том, что улучшение качества было достигнуто не за счёт формального усложнения архитектуры, а за счёт содержательной организации всей исследовательской схемы. Было показано, что инженерия признаков, аккуратное построение временных признаков и корректное разбиение по годам оказывают существенное влияние на итоговое качество прогноза. Такой вывод важен не только для рассматриваемой задачи, но и для более широкого круга прикладных работ, где временная структура данных и риск утечки будущей информации

могут существенно искажать результаты моделирования.

Личный вклад автора состоял в полной реализации всей исследовательской схемы. Автором были подготовлены и структурированы исходные данные, выполнены предобработка и очистка данных, реализовано построение признаков, включая временные и комбинированные варианты, организована корректная схема разбиения данных по годам, проведены вычислительные эксперименты для различных семейств моделей и выполнен анализ полученных результатов. Тем самым автором был реализован полный цикл работы — от подготовки данных и построения моделей до интерпретации итоговых выводов.

При этом исследование имело ряд ограничений. Работа была выполнена на доступном объёме сезонных данных, что ограничивало возможности более сложных моделей и накладывало естественные требования на интерпретацию результатов. Дополнительное влияние на постановку оказывал дисбаланс классов, из-за которого качество модели необходимо было оценивать с особым вниманием к *Precision*, *Recall* и *PR-AUC*. Кроме того, полученные выводы относились именно к задаче прогноза по использованным погодным и производным признакам на горизонте двух дней и требовали отдельной проверки при переносе на иные условия применения.

В качестве направлений дальнейшего развития целесообразно рассматривать расширение массива сезонных данных, дальнейшее развитие признакового описания при сохранении сезонной корректности, а также дополнительное исследование ансамблевых подходов и устойчивости модели при переносе на новые условия наблюдения. В целом поставленная цель была достигнута: метод прогнозирования благоприятных условий развития фитофтороза картофеля по сезонным погодным данным был разработан, реализован и исследован в единой корректной экспериментальной постановке.

Литература

- [1] P. Chowdappa et al. Severe outbreaks of late blight on potato and tomato. *Phytopathology Research*, 2014.
- [2] Potato News Today. From blight alerts to field decisions: Are forecast apps finally accurate enough, 2025.
- [3] J. S. Castaño Serna et al. Meta-analysis on criteria and forecasting models for potato late blight. *Agriculture*, 2025.
- [4] P. Bagchi et al. Potato late blight outbreak: A study on advanced classification models based on meteorological data. *Sensors*, 2024.
- [5] A review of machine learning models for plant disease detection: Challenges and future directions. *Frontiers in Plant Science*. <https://www.frontiersin.org/journals/plant-science/articles/10.3389/fpls.2025.1499909/full>, 2025.
- [6] Negfry: A new forecasting model for potato late blight. *Phytopathology*. <https://pubmed.ncbi.nlm.nih.gov/39686401/>, 2024.
- [7] A hybrid stacked classifier for predicting potato late blight outbreaks using meteorological features. <https://www.scirp.org/journal/paperinformation?paperid=144925>.
- [8] Model for training and predicting the occurrence of potato. <https://thesai.org/Downloads/Volume16No2/Paper13-ModelforTrainingandPredictingtheOccurrenceofPotato.pdf>.
- [9] Deep learning for time series forecasting in agricultural systems. *CEUR Workshop Proceedings*. <https://ceur-ws.org/Vol-3944/paper2.pdf>, 2024.
- [10] Potato late blight (*phytophthora infestans*) disease forecasting using an auto-encoded long short-term memory recurrent neural networks in north-western algeria. <https://www.researchgate.net/>.
- [11] T. Miftahushudur et al. A survey of methods for addressing imbalance data problems in agriculture. *Remote Sensing*, 2025.
- [12] Optimized classification thresholds in agricultural diagnostic systems to address imbalanced data. <https://pmc.ncbi.nlm.nih.gov/articles/PMC12436414/>, 2024.
- [13] Optimization of classification threshold for imbalanced data in agriculture using integer linear programming. *Mathematics*. <https://www.mdpi.com/2227-7390/13/7/1059>, 2025.

- [14] The cost of false negatives in precision agriculture: A case study on late blight forecasting. Remote Sensing. <https://www.mdpi.com/2072-4292/17/3/454>, 2025.